

Predicción del valor de ICP y su lateralización en pacientes pediátricos en cuidados neurocríticos usando modelos LSTM

Edu Marin, Gianfranco Fera, Arelí Sanchez and Luis Barreto

Abstract—The abstract goes here.

Index Terms—IEEE, IEEEtran, journal, LATEX, paper, template.

I. INTRODUCCIÓN

EN el contexto de las enfermedades neurológicas como la lesión cerebral traumática (TBI) [1], el accidente cerebrovascular (ACV) [2] o la hemorragia subaracnoidea (SAH) [3], parámetros como la presión intracraneal (ICP), la presión arterial (ABP) y la velocidad de flujo sanguíneo cerebral (CBFV) son indicadores fundamentales en la evaluación de la dinámica cerebral y en situaciones de emergencia neurológica [4]. La monitorización de estos parámetros es clave para entender cómo diversas condiciones neurológicas afectan la presión dentro del cráneo y la perfusión cerebral, aspectos críticos en la gestión de pacientes con condiciones agudas y potencialmente mortales. Estos indicadores permiten una comprensión más profunda de las complejidades asociadas con la regulación autónoma cerebrovascular (CAR) y su impacto en la patofisiología de estas condiciones [1].

En particular, el accidente cerebrovascular (ACV) en pediatría, aunque menos frecuente que en adultos, constituye un desafío significativo en el ámbito de la neurología infantil. La incidencia anual se estima entre 2.5 y 3 casos por 100,000 niños, cifra que asciende con la edad. Esta patología, que incluye tanto eventos isquémicos como hemorrágicos, puede surgir en niños previamente sanos y representa una de las principales causas de muerte y discapacidad a largo plazo en este grupo etario [5].

A pesar de ello, los métodos actuales para monitorizar la presión intracraneal en niños, especialmente críticos en casos de ACV hemorrágico, aún requieren mejoras para adaptarse a las particularidades fisiológicas pediátricas [6]. Los avances en tecnología de monitorización podrían ofrecer herramientas más precisas y menos invasivas, contribuyendo significativamente a la gestión de la presión intracraneal y la reducción de la morbilidad asociada con estas condiciones.

En este contexto, el aprendizaje automático (Machine Learning, ML) es un campo de la inteligencia artificial que ha demostrado un gran potencial para el análisis de datos

en diversos campos, incluida la medicina [7], el campo de la neurociencia y los cuidados críticos [8]. En los procesos de aprendizaje supervisado, el algoritmo es instruido mediante un conjunto de datos previamente etiquetados, como en el caso de la detección de patrones anormales en el entrenamiento de software para el diagnóstico de la epilepsia. Por otro lado, en el aprendizaje no supervisado, se emplea un algoritmo para identificar patrones emergentes o valores atípicos en datos no etiquetados que son introducidos para su análisis [7].

En este estudio, se busca aplicar un enfoque de regresión y aprendizaje supervisado utilizando LSTM para la predicción no invasiva de la presión intracraneal (ICP), con el objetivo de desarrollar intervenciones más efectivas y oportunas.

A. Marco Teórico

1) *Contexto médico*: La presión intracraneal (ICP) es un parámetro crítico en el manejo de pacientes con afecciones neurológicas severas, como lesiones cerebrales traumáticas y accidentes cerebrovasculares hemorrágicos [9]. La presión arterial (ABP) y la velocidad de flujo sanguíneo cerebral (CBFV) son esenciales para entender la dinámica vascular cerebral y para guiar el tratamiento en pacientes con condiciones neurológicas agudas [9], [10].

2) *Trasfondo técnico*: El aprendizaje automático ha revolucionado muchos campos, incluida la atención médica, donde ha demostrado ser una herramienta con gran potencial para el diagnóstico, la predicción y el tratamiento de diversas enfermedades. En particular, en el ámbito de la salud, el aprendizaje automático se utiliza para analizar grandes volúmenes de datos, desde registros médicos electrónicos hasta imágenes médicas y señales fisiológicas, con el fin de extraer información relevante que pueda mejorar la atención al paciente y la toma de decisiones clínicas [11], [12]. Una de las áreas clave en las que el aprendizaje automático ha tenido un impacto significativo es en el modelado de datos dependientes del tiempo. Esto se refiere a datos que varían con el tiempo y están interconectados de alguna manera, como las series temporales de señales fisiológicas, que incluyen el electrocardiograma (ECG), la electroencefalografía (EEG) y la electromiografía (EMG), entre otros [13], [14], [15]. Estas señales proporcionan información vital sobre el funcionamiento del cuerpo humano y se utilizan en una amplia gama de aplicaciones médicas, desde el diagnóstico de enfermedades cardíacas hasta la monitorización del sueño. Entre las herramientas más utilizadas para modelar datos temporales

M. Shell was with the Department of Electrical and Computer Engineering, Georgia Institute of Technology, Atlanta, GA, 30332 USA e-mail: (see <http://www.michaelshell.org/contact.html>).

J. Doe and J. Doe are with Anonymous University.

Manuscript received April 19, 2005; revised August 26, 2015.

se encuentran las redes neuronales recurrentes (RNN) [16], diseñadas específicamente para manejar secuencias de datos. Una variante son las Long Short-Term Memory (LSTM) [17], las cuales permiten capturar dependencias a largo plazo en los datos y son ampliamente utilizadas en aplicaciones de series temporales. Además, están sus variantes bidireccionales [18], las cuales se emplean para comprender el contexto completo de una secuencia de datos, a diferencia de las LSTM unidireccionales que procesan la secuencia en una sola dirección (de pasado a futuro), las LSTM bidireccionales procesan los datos tanto hacia adelante como hacia atrás. Algunos trabajos han utilizado LSTM bidireccionales para la evaluación de señales fisiológicas, demostrando su eficacia en tareas de análisis de datos biomédicos. [19], [20]

B. Objetivos del Proyecto

1) *Objetivo General:* Desarrollar y validar un modelo de aprendizaje automático para predecir de manera continua la presión intracraneal (ICP) en pacientes pediátricos en cuidados neurocríticos.

2) *Objetivos Específicos:*

- Implementar un modelo de regresión para predecir tempranamente la ICP en situaciones críticas.
- Clasificar a los pacientes según la gravedad de su condición basándose en las características de las señales fisiológicas.
- Identificar las variables más relevantes para la predicción de la ICP mediante técnicas de selección de características.
- Validar el modelo de regresión utilizando métricas de evaluación de rendimiento como precisión y sensibilidad.
- Interpretar los resultados del modelo en el contexto clínico y discutir su aplicabilidad y limitaciones.

II. MÉTODOS

A. Metodología

1) *Preparación de Datos:*

Recolección y Acceso: Obtener acceso a la base de datos de PhysioNet, una fuente pública de registros de señales fisiológicas y datos clínicos. Cargar los datos relevantes en un entorno seguro de procesamiento de datos, asegurando la conformidad con las normativas de privacidad y protección de datos.

Exploración, Limpieza y Normalización: Realizar un análisis exploratorio inicial para identificar patrones, valores atípicos y posibles errores en los datos. Aplicar técnicas de limpieza para corregir o eliminar registros erróneos o incompletos. Normalizar las señales fisiológicas para homogeneizar la escala y facilitar su comparación y análisis.

Data Augmentation: Aplicar técnicas de data augmentation a los datos de señales fisiológicas para aumentar la diversidad y el volumen del conjunto de datos.

2) *Extracción y Selección de Características:*

Extracción: Desarrollar algoritmos para extraer características cuantitativas de las señales fisiológicas. Implementar métodos de procesamiento de señales para extraer información relevante desde el punto de vista clínico.

Selección: Utilizar técnicas estadísticas y de machine learning para identificar las características más relevantes para los modelos predictivos.

3) *Modelado y Validación:*

Modelos de Machine Learning: Incorporar modelos LSTM para regresión y desarrollar modelos de clasificación para ICP lateralizada. Aplicar modelos ensemble para mejorar la precisión y la estabilidad.

Evaluación: Evaluar el rendimiento de los modelos utilizando métricas específicas como precisión, sensibilidad, especificidad, y el área bajo la curva ROC (AUC).

B. Aplicación y Documentación

Interpretación de Resultados: Analizar e interpretar los resultados obtenidos de los modelos en el contexto clínico para entender su aplicabilidad y limitaciones.

Desarrollo de Herramientas: Crear prototipos de herramientas de software que integren los modelos desarrollados, diseñados para ser utilizados por el personal clínico en la monitorización y toma de decisiones en tiempo real.

Documentación: Elaborar documentación detallada sobre los métodos utilizados, los modelos desarrollados, y los resultados obtenidos.

C. Consideraciones Éticas

Consentimiento Informado y Aprobación Ética: Asegurar la transparencia sobre el origen y uso de los datos y obtener la aprobación ética necesaria para el uso del dataset de PhysioNet.

Uso Apropiado de los Datos y Beneficio Social: Los datos serán utilizados exclusivamente para los fines declarados en el estudio, maximizando el beneficio social del estudio y comunicando los resultados de manera responsable.

III. RESULTADOS Y DISCUSIÓN

Se han probado seis modelos LSTM variando diferentes parámetros, tales como la cantidad de capas, el número de unidades en cada capa, y las tasas de aprendizaje. Cada modelo fue evaluado minuciosamente para determinar su precisión y capacidad de generalización en la estimación de la presión intracraneal.

Los resultados de la estimación de la presión intracraneal (ICP) han sido óptimos utilizando redes neuronales bidireccionales LSTM. Este enfoque ha demostrado una alta precisión y fiabilidad en la predicción de los valores de ICP, superando a otros métodos tradicionales. La capacidad de las redes LSTM bidireccionales para considerar tanto la información pasada como la futura ha permitido modelar de manera más efectiva las complejas dinámicas temporales de los datos de ICP, proporcionando una herramienta invaluable para el monitoreo y tratamiento de pacientes con condiciones neurológicas críticas.

El modelo no presenta overfitting, ya que se han ploteado las pérdidas de entrenamiento y validación a lo largo de las épocas, observándose que convergen juntas. Este comportamiento indica que el modelo generaliza bien a datos no vistos, manteniendo su capacidad predictiva tanto en el

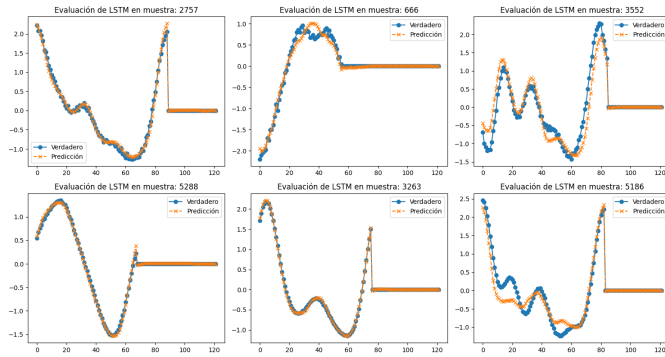


Fig. 1. Figura 1. Resultados de diversas predicciones de ICP normalizados.

conjunto de entrenamiento como en el de validación. La convergencia de las curvas de pérdida refuerza la confianza en la robustez y efectividad del modelo para estimar con precisión la presión intracraneal.




Fig. 2. Figura 3. Revisión de overfitting.

IV. CONCLUSIÓN

Es posible estimar una onda normalizada de la presión intracraneal (ICP) a través de la presión intracraneal y el flujo sanguíneo cerebral, para luego reconstruirla mediante una estimación de la media y la desviación estándar de estas mismas señales. Este enfoque representa un avance metodológico significativo, ya que ofrece una alternativa menos invasiva a los métodos actuales utilizados para medir la presión intracraneal. La capacidad de obtener mediciones precisas y fiables sin la necesidad de intervenciones invasivas podría transformar el manejo clínico de pacientes con condiciones neurológicas, mejorando la seguridad y el confort del paciente.

AGRADECIMIENTOS

REFERENCES

- [1] S. P. Klein, B. Depreitere, and G. Meyfroidt, "How i monitor cerebral autoregulation," *Critical Care*, vol. 23, May 2019.
- [2] A. Frattalone and W. C. Ziai, "Intracranial pressure monitoring in cerebrovascular disease," *Cambridge University Press eBooks*, pp. 3–19, 06 2014.
- [3] A. Addis, M. Baggiani, and G. Citerio, "Intracranial pressure monitoring and management in aneurysmal subarachnoid hemorrhage," *Neurocritical care*, vol. 39, 06 2023.
- [4] X. Liu, Y. Pu, D. Wu, Z. Zhang, X. Hu, and L. Liu, "Cross-frequency coupling between cerebral blood flow velocity and eeg in ischemic stroke patients with large vessel occlusion," *Frontiers in neurology*, vol. 10, Mar 2019.
- [5] C. B. Dabdoub *et al.*, "Accidente cerebrovascular: un manto oscuro en pediatría," *Rev. bol. ped.*, vol. 53, no. 3, pp. 129–136, 2014.
- [6] X. Zhang, J. E. Medow, B. J. Iskandar, F. Wang, M. Shokouinejad, J. Koueik, and J. G. Webster, "Invasive and noninvasive means of measuring intracranial pressure: a review," *Physiological measurement*, vol. 38, no. 8, p. R143, 2017.
- [7] Y. KH, B. AL, and K. IS, "Artificial intelligence in healthcare," *Nature Biomedical Engineering*, vol. 2, pp. 719–731, 2018.
- [8] N. Phutela, D. Relan, G. Gabrani, P. Kumaraguru, and M. Samuel, "Stress classification using brain signals based on lstm network," *Computational Intelligence and Neuroscience*, vol. 2022, pp. 1–13, Apr 2022.
- [9] R. Jaishankar, A. Fanelli, A. Filippidis, T. Vu, J. Holsapple, and T. Heldt, "A spectral approach to model-based noninvasive intracranial pressure estimation," *IEEE journal of biomedical and health informatics*, vol. 24, pp. 2398–2406, Aug 2020.
- [10] A. Fanelli *et al.*, "Fully automated, real-time, calibration-free, continuous noninvasive estimation of intracranial pressure in children," *Journal of Neurosurgery: Pediatrics*, vol. 24, pp. 509–519, Nov 2019.
- [11] S. Yeasmin, "Benefits of artificial intelligence in medicine," pp. 1–6, 2019.
- [12] . Amisha, P. Malik, M. Pathania, and V. K. Rathaur, "Overview of artificial intelligence in medicine," vol. 8, no. 7, pp. 2328–2331, 2019.
- [13] D. Jyotishi and S. Dandapat, "An lstm-based model for person identification using eeg signal," *IEEE Sensors Letters*, vol. 4, no. 8, pp. 1–4, 2020.
- [14] G. Zhang, V. Davoodnia, A. Sepas-Moghaddam, Y. Zhang, and A. Etemad, "Classification of hand movements from eeg using a deep attention-based lstm network," *IEEE Sensors Journal*, vol. 20, no. 6, pp. 3113–3122, 2020.

- [15] T. Bao, S. A. R. Zaidi, S. Xie, P. Yang, and Z.-Q. Zhang, “A cnn-lstm hybrid model for wrist kinematics estimation using surface electromyography,” *IEEE Transactions on Instrumentation and Measurement*, vol. 70, pp. 1–9, 2021.
- [16] J. L. Elman, “Finding structure in time,” *Cognitive Science*, vol. 14, no. 2, pp. 179–211, 1990.
- [17] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [18] M. Schuster and K. K. Paliwal, “Bidirectional recurrent neural networks,” *IEEE Transactions on Signal Processing*, vol. 45, pp. 2673–2681, 1997.
- [19] C. Jiao, C. Chen, S. Gou, D. Hai, B.-Y. Su, M. Skubic, L. Jiao, A. Zare, and K. C. Ho, “Non-invasive heart rate estimation from ballistocardiograms using bidirectional lstm regression,” *IEEE Journal of Biomedical and Health Informatics*, vol. 25, no. 9, pp. 3396–3407, 2021.
- [20] C. Ma, C. Lin, O. Samuel, G. Weiyu, H. Zhang, S. Greenwald, L. Xu, and P. Li, “A bi-directional lstm network for estimating continuous upper limb movement from surface electromyography,” *IEEE Robotics and Automation Letters*, vol. 6, 07 2021.